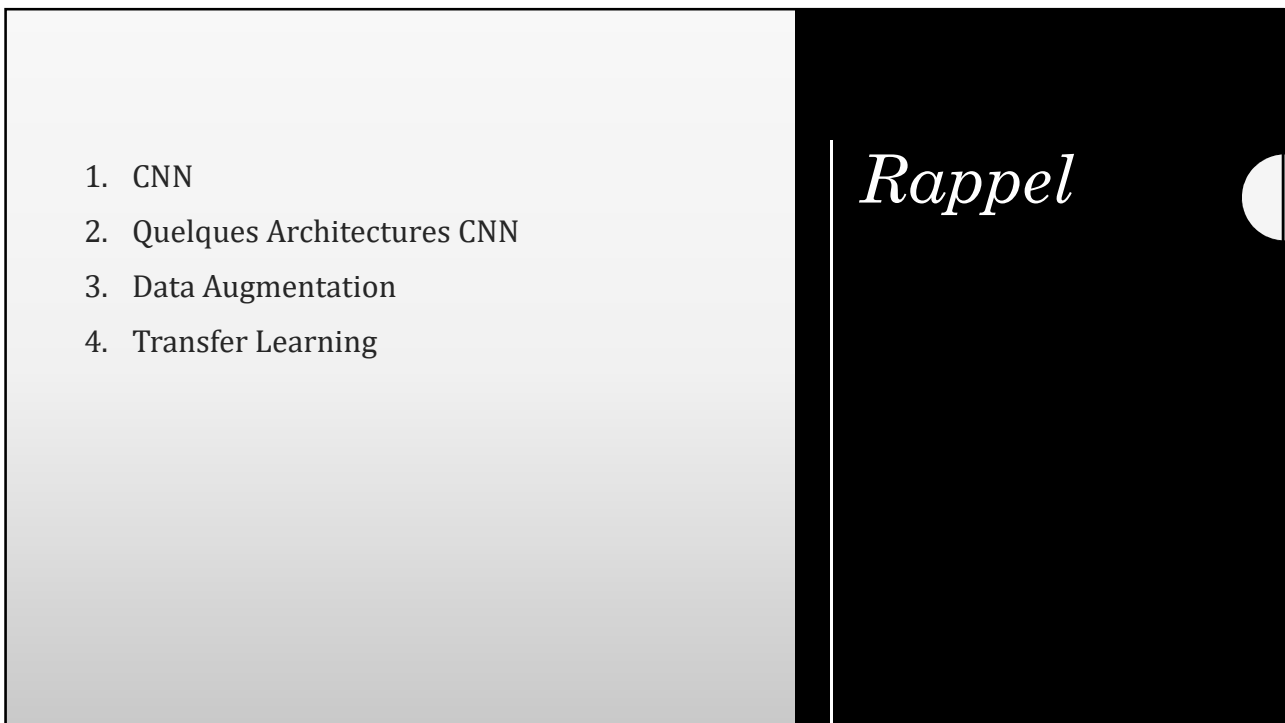


1



2

Generative Adversial Networks: (GAN)

3

GAN:quoi?

- Des modèles génératifs qui utilisent des techniques d'apprentissage profond
- Une méthode non-supervisée générative:
 - Les données ne sont pas labelisées ni catégorisées.
 - Pas de généralisation pour la prédiction des classes de nouvelles données.
- Un GAN découvre automatiquement des motifs (pattern) à partir d'un ensemble de données, et est capable de générer des données vraisemblables.

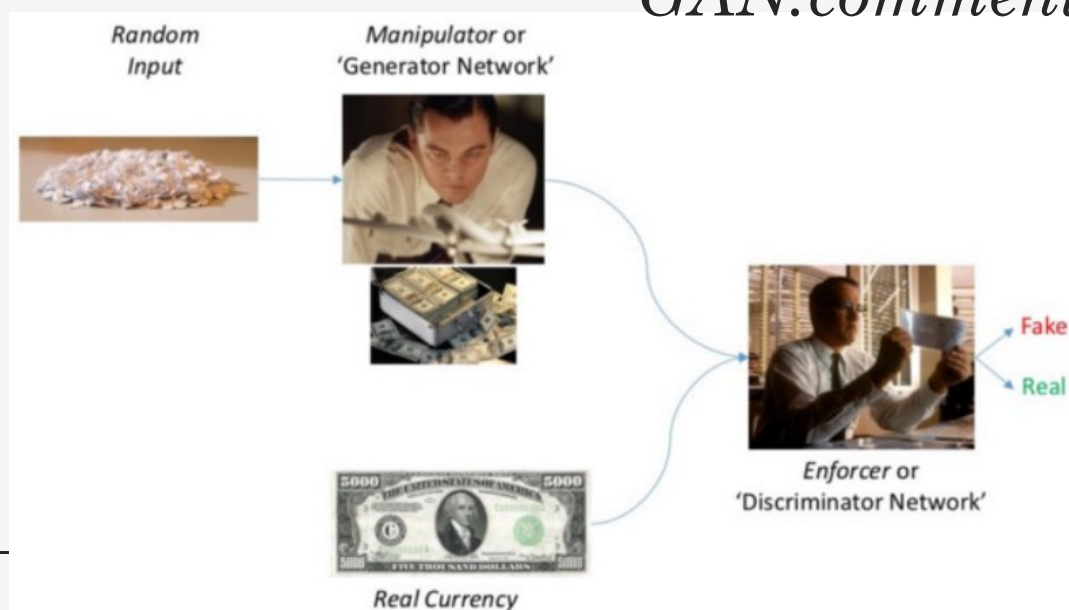
4

GAN:comment?

- GAN est formalisé comme un problème supervisé pour réaliser une tâche non supervisée:
- Composé d'une paire de réseaux de neurones: generator G /discriminator D :
 - G produit de nouvelles images et
 - D essaye de distinguer les images générées des réelles. (partie supervisée)
- Les deux modèles sont entraînés ensemble de façon antagoniste à somme nulle.
- G essaye de tromper D , et D essaye de rester discriminant.

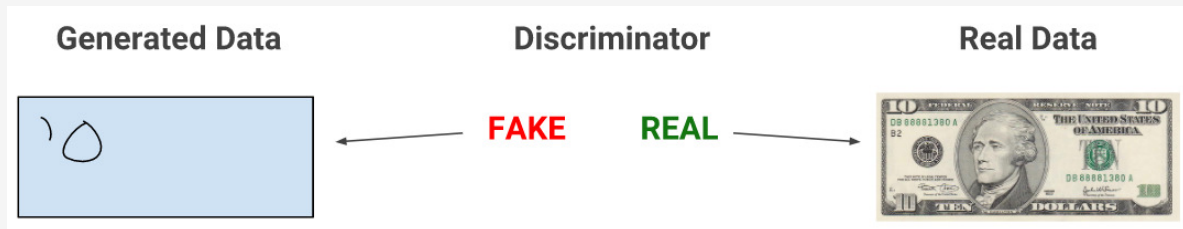
5

GAN:comment?




6

GAN:comment?




7

GAN:comment?



8

GAN:comment?



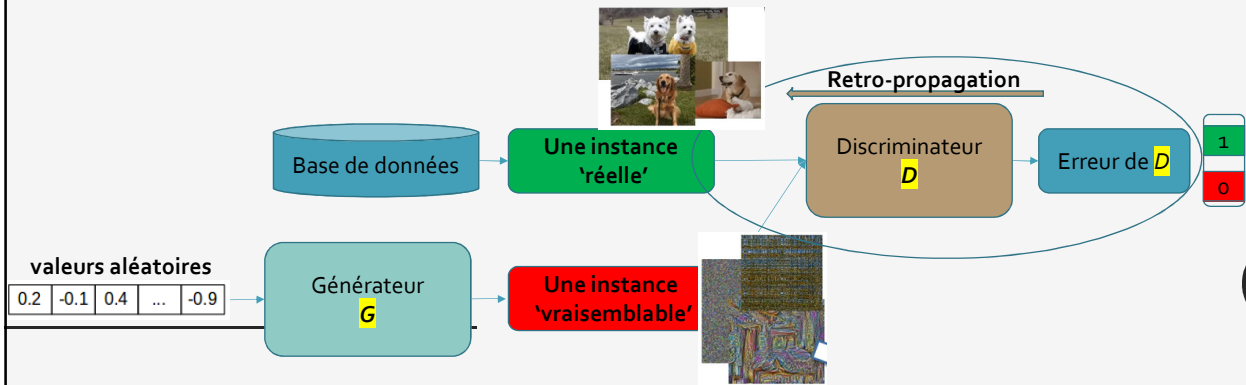
9

GAN:détails

10

GAN: discriminator (D)

- **Le discriminateur D** (classifieur binaire)
- Les données pour entraîner le discriminateur proviennent de:
 - **Données réelles**: de la base de données, annotées (1)
 - **Données vraisemblables**: créées par le générateur, annotées (0)
- Calcul de l'erreur de D et mise à jour de ses poids par retro-propagation.




11

GAN: discriminator loss

- Le Discriminateur D veut:
 - Reconnaître **une vraie** image x comme 'vraie' => valeur prédite proche de 1

Label = 1 valeur erreur grande


Pred = 0.1



12

GAN: discriminator loss

- Le Discriminateur D veut:
 - Reconnaître **une vraie** image x comme 'vraie' => valeur prédite proche de **1**



13


GAN: discriminator loss

- Le Discriminateur D veut:
 - Reconnaître **une vraie** image x comme 'vraie' => valeur prédite proche de **1**

Label = 1 valeur erreur grande $-\ln(0.1) = 2.3$
Pred = 0.1

$$L = -\ln(\text{Pred})$$

Label = 1 valeur erreur faible $-\ln(0.9) = 0.1$
Pred = 0.9

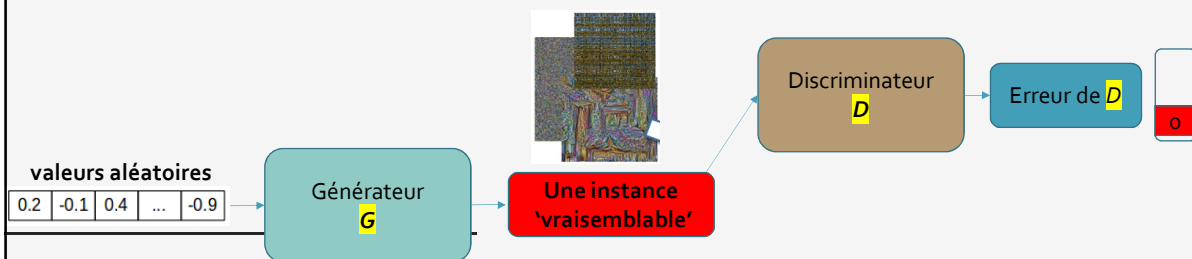


14

GAN: discriminator loss

- Le Discriminateur D veut:
 - Reconnaître **une fausse** image x comme 'fausse' => valeur prédite proche de **0**

Label = 0 valeur erreur faible
Pred = 0.1




15

GAN: discriminator loss

- Le Discriminateur D veut:
 - Reconnaître **une fausse** image x comme 'fausse' => valeur prédite proche de **0**

Label = 0 valeur erreur grande
Pred = 0.9



16

GAN: discriminator loss

- Le Discriminateur D veut:

➤ Reconnaître **une fausse** image x comme 'fausse' \Rightarrow valeur prédite proche de **0**


Label = 0 valeur erreur faible $-\ln(1-0.1) = -\ln(0.9) = 0.1$

Pred = 0.1

$$L = -\ln(1-\text{Pred})$$

Label = 0 valeur erreur grande $-\ln(1-0.9) = -\ln(0.1) = 2.3$

Pred = 0.9

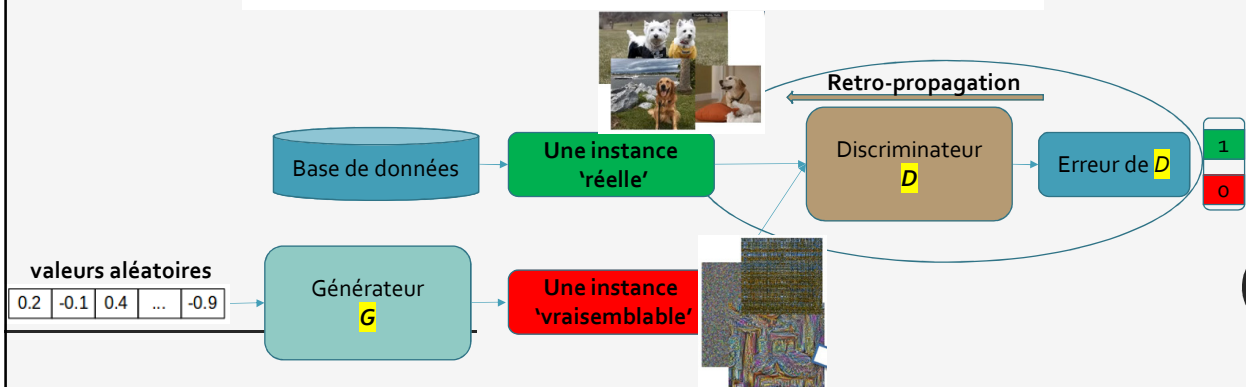


17

GAN: discriminator (D)

- Discriminator-loss

$$\nabla_{\theta_d} \frac{1}{m} \sum_{i=1}^m \left[\log D(x^{(i)}) + \log (1 - D(G(z^{(i)}))) \right]$$



18

GAN: generator (G)

- Un **générateur G** apprend à générer des données vraisemblables à partir d'un vecteurs de valeurs aléatoires.
- Calculer la fonction d'erreur du discriminateur.
- Retro-propager à travers le discriminateur et le générateur.
- Mettre à jours les poids du générateur G **uniquement**. Les poids de D restent inchangés.



19

GAN: generator (G)

- Le Générateur G veut:
 - Générer de fausses images $G(z)$ que le discriminateur prend pour **réelles**.
- Label = 1 valeur erreur grande
Pred = 0.1



20

GAN: generator (G)

- Le Générateur G veut:
 - Générer de fausses images $G(z)$ que le discriminateur prend pour **réelles**.

Label = 1 valeur erreur faible
Pred = 0.9



21

GAN: generator (G)

- Le Générateur G veut:
 - Générer de fausses images $G(z)$ que le discriminateur prend pour **réelles**.

Label = 1 valeur erreur grande $-\ln(0.1) = 2.3$
Pred = 0.1

$$L = -\ln(\text{Pred})$$

Label = 1 valeur erreur faible $-\ln(0.9) = 0.1$
Pred = 0.9



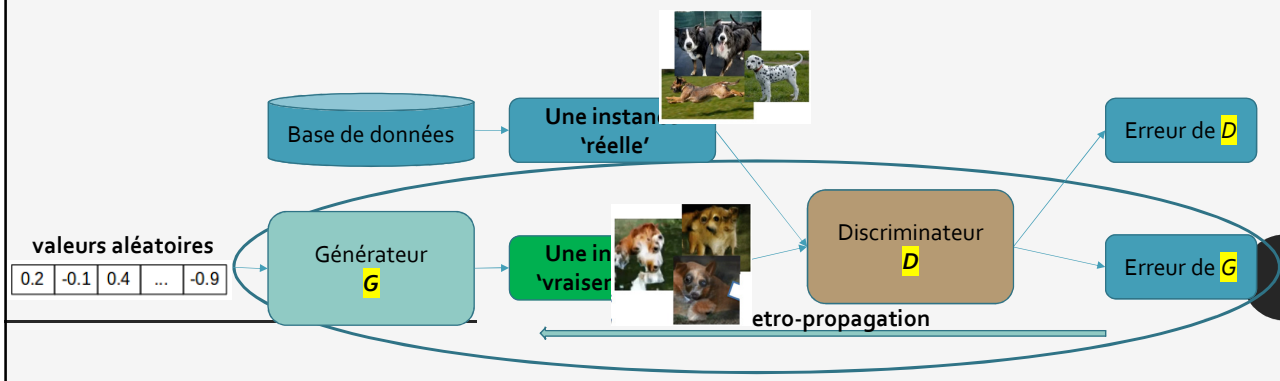
22

GAN: generator (G)

- Generator-loss :

$$\nabla_{\theta_g} \frac{1}{m} \sum_{i=1}^m \log (1 - D (G (z^{(i)})))$$

- Au lieu d'entraîner G à minimiser $\log(1-D(G(z)))$, on l'entraîne à maximiser $\log(D(G(z)))$.



23

GAN: zero-sum game

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{\text{data}}(x)} [\log(\text{Score de sortie pour une vraie image } D(x))] + \mathbb{E}_{z \sim p_z(z)} [\log(\text{Score de sortie pour une image produite par G } (1 - D(G(z))))]$$

- Le Discriminateur D veut:
 - Reconnaître une vraie image x comme 'vraie' => un score proche de 1
 - Reconnaître une fausse image x comme 'fausse' => un score proche de 0
- Le Générateur G veut:
 - Générer de fausses images $G(z)$ que le discriminateur prend pour réelles.

24

GAN: Algorithm

Algorithm 1 Minibatch stochastic gradient descent training of generative adversarial nets. The number of steps to apply to the discriminator, k , is a hyperparameter. We used $k = 1$, the least expensive option, in our experiments.

for number of training iterations **do**

for k steps **do**

- Sample minibatch of m noise samples $\{z^{(1)}, \dots, z^{(m)}\}$ from noise prior $p_g(z)$.
- Sample minibatch of m examples $\{x^{(1)}, \dots, x^{(m)}\}$ from data generating distribution $p_{\text{data}}(x)$.
- Update the discriminator by ascending its stochastic gradient:

$$\nabla_{\theta_d} \frac{1}{m} \sum_{i=1}^m \left[\log D(x^{(i)}) + \log (1 - D(G(z^{(i)}))) \right].$$

end for

- Sample minibatch of m noise samples $\{z^{(1)}, \dots, z^{(m)}\}$ from noise prior $p_g(z)$.
- Update the generator by descending its stochastic gradient:


$$\nabla_{\theta_g} \frac{1}{m} \sum_{i=1}^m \log (1 - D(G(z^{(i)}))).$$

end for

The gradient-based updates can use any standard gradient-based learning rule. We used momentum in our experiments.

25

GAN: Algorithm



26

GAN: applications



Radford, Alec, Luke Metz, and Soumith Chintala. "Unsupervised representation learning with deep convolutional generative adversarial networks." *arXiv preprint arXiv:1511.06434* (2015).

27


GAN: applications: synthetic faces



Karras, Tero, et al. "Progressive growing of gans for improved quality, stability, and variation." *arXiv preprint arXiv:1710.10196* (2017).

28

GAN: applications



Radford, Alec, Luke Metz, and Soumith Chintala. "Unsupervised representation learning with deep convolutional generative adversarial networks." *arXiv preprint arXiv:1511.06434* (2015).

29

GAN: applications: realistic images



Brock, Andrew, Jeff Donahue, and Karen Simonyan. "Large scale gan training for high fidelity natural image synthesis." *arXiv preprint arXiv:1809.11096* (2018).

30


GAN: applications: anime characters



Jin, Yanghua, et al. "Towards the automatic anime characters creation with generative adversarial networks." *arXiv preprint arXiv:1708.05509* (2017)

31

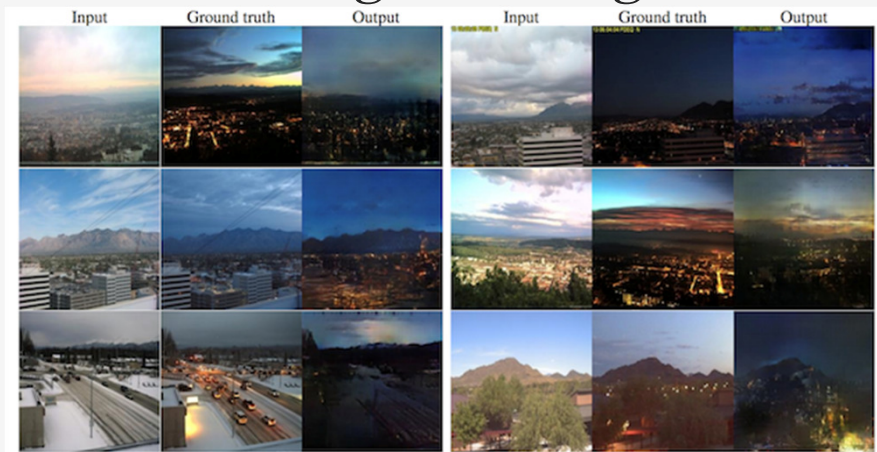
GAN: applications: Project PokeGAN



<https://awesomeopensource.com/project/moxiegushi/pokeGAN>

32

GAN: applications: image-to-image translation



Isola, Phillip, et al. "Image-to-image translation with conditional adversarial networks." *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2017.

33


GAN: applications: image-to-image translation



Isola, Phillip, et al. "Image-to-image translation with conditional adversarial networks." *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2017.

34


GAN: applications: semantic-image-to-photo translation



Wang, Ting-Chun, et al. "High-resolution image synthesis and semantic manipulation with conditional gans." *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2018.

35

GAN: applications: face aging



Zhang, Zhifei, Yang Song, and Hairong Qi. "Age progression/regression by conditional adversarial autoencoder." *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2017.

36

Références

- <https://towardsdatascience.com/image-classification-in-10-minutes-with-mnist-dataset-54c35b77a38d>
- <http://scs.rverson.ca/~aharley/vis/conv/flat.html>
- <https://medium.com/@ageitgey/machine-learning-is-fun-part-3-deep-learning-and-convolutional-neural-networks-f40359318721>
- http://mlss.tuebingen.mpg.de/2015/slides/fergus/Fergus_1.pdf
- <http://cs231n.github.io/assets/conv-demo/index.html>
- <http://cs231n.github.io/convolutional-networks/>
- <https://uijwalkarn.me/2016/08/11/intuitive-explanation-convnets/>
- <http://neuralnetworksanddeeplearning.com/chap1.html>
- <http://cedric.cnam.fr/vertigo/Cours/ml2/preambule.html>
- <http://cs231n.github.io/convolutional-networks/#case>
- <https://www.learnopencv.com/number-of-parameters-and-tensor-sizes-in-convolutional-neural-network/>
- <https://medium.com/@RaghavPrabhu/cnn-architectures-lenet-alexnet-vgg-googlenet-and-resnet-7c81c017b848>
- <https://towardsdatascience.com/illustrated-10-cnn-architectures-95d78ace614d#a253>
- <https://www.youtube.com/watch?v=c1RBQzKsDCk&list=PLkDaE6sCZn6Gl29AoE31iwdVwSG-KnDzF&index=17&t=0s&pbjreload=10>

37

Références

- <http://cs231n.github.io/convolutional-networks/#case>
- <https://www.learnopencv.com/number-of-parameters-and-tensor-sizes-in-convolutional-neural-network/>
- <https://medium.com/@RaghavPrabhu/cnn-architectures-lenet-alexnet-vgg-googlenet-and-resnet-7c81c017b848>
- <https://towardsdatascience.com/illustrated-10-cnn-architectures-95d78ace614d#a253>
- <https://www.youtube.com/watch?v=c1RBQzKsDCk&list=PLkDaE6sCZn6Gl29AoE31iwdVwSG-KnDzF&index=17&t=0s&pbjreload=10>
- <https://www.pyimagesearch.com/2019/07/08/keras-imagedatagenerator-and-data-augmentation/>
- <https://machinelearningmastery.com/how-to-configure-image-data-augmentation-when-training-deep-learning-neural-networks/>
- <https://keras.io/preprocessing/image/>
- <https://towardsdatascience.com/a-comprehensive-hands-on-guide-to-transfer-learning-with-real-world-applications-in-deep-learning-212bf3b2f27a>
- <http://cs231n.github.io/transfer-learning/>
- <https://towardsdatascience.com/what-is-deep-transfer-learning-and-why-is-it-becoming-so-popular-91acdcc2717a>
- <https://towardsdatascience.com/a-comprehensive-hands-on-guide-to-transfer-learning-with-real-world-applications-in-deep-learning-212bf3b2f27a>
- <http://cedric.cnam.fr/vertigo/Cours/ml2/docs/coursDeep5.pdf>

38